

Scaling Amazon EC2

★ Mục Tiêu Bài Học

- Nhận biết khái niệm **scalability** và **elasticity** trong AWS.
- Mô tả cách AWS giúp doanh nghiệp điều chỉnh năng lực tính toán (compute capacity) theo nhu cầu thay đổi.

Một website không tải được và liên tục timeout thường là do nhận quá nhiều request so với khả năng xử lý. Scalability giúp xử lý nhu cầu dao động bằng cách điều chỉnh compute capacity.

Ý Chính

Scalability là tiềm năng của hệ thống để phát triển theo thời gian, còn **elasticity** là việc điều chỉnh tài nguyên linh hoạt, theo yêu cầu.

★ Scalability

Khả năng của hệ thống xử lý tải tăng lên bằng cách **thêm tài nguyên**.

- Scale up:** thêm sức mạnh cho máy hiện có.
- Scale out:** thêm nhiều máy.
- Tập trung vào **lập kế hoạch dung lượng dài hạn** để hệ thống đón thêm người dùng hoặc workload khi cần.

★ Elasticity


Khả năng **tự động** tăng hoặc giảm tài nguyên theo nhu cầu thời gian thực.

- Scale out khi nhu cầu cao, **scale in** khi nhu cầu giảm.
- Điều chỉnh nhanh chóng.
- Mang lại **hiệu quả chi phí** và dùng tài nguyên tối ưu tại mọi thời điểm.


★ So Sánh Scalability và Elasticity

Tiêu chí	Scalability	Elasticity
Bản chất	→ Xử lý tải tăng bằng cách thêm tài nguyên	→ Tự động tăng/giảm theo nhu cầu thực
Thời gian	→ Dài hạn, lập kế hoạch dung lượng	→ Thời gian thực, theo yêu cầu
Hướng	→ Phát triển (scale up / scale out)	→ Hai chiều (scale out / scale in)
Lợi ích	→ Hệ thống đón thêm người dùng, workload	→ Tiết kiệm chi phí, tối ưu tài nguyên

★ Scaling Up và Scaling Out



Scaling up



Scaling out

- **Scaling up:** một máy được thay bằng máy mạnh hơn (nét đứt chỉ hướng tăng sức mạnh).
- **Scaling out:** số lượng máy tăng lên; máy nét đứt là phần có thể thêm vào nhóm.

★ Amazon EC2 Auto Scaling

Tự động điều chỉnh **số lượng EC2 instance** theo thay đổi nhu cầu của ứng dụng, giúp **tăng tính sẵn sàng** (availability).

Bạn duy trì lượng compute capacity mong muốn bằng cách điều chỉnh số instance động theo nhu cầu.

Hai Cách Tiếp Cận


- **Dynamic scaling:** điều chỉnh theo thời gian thực khi nhu cầu dao động.
- **Predictive scaling:** lên lịch trước số instance phù hợp dựa trên nhu cầu dự đoán.

★ Auto Scaling Group

Bạn tạo **Auto Scaling group**: tập hợp các EC2 instance có thể scale in hoặc scale out để đáp ứng nhu cầu ứng dụng. Mỗi group được cấu hình với ba thiết lập chính.

Thiết lập	Ý nghĩa	Ví dụ
Minimum capacity	→ Số instance ít nhất để ứng dụng chạy; hệ thống không bao giờ scale xuống dưới mức này. Đây cũng là số instance được khởi chạy ngay sau khi tạo group.	4 instance
Desired capacity	→ Số instance lý tưởng cho workload hiện tại, Auto Scaling cố gắng duy trì. Nếu không chỉ định thì mặc định bằng minimum capacity.	6 instance
Maximum capacity	→ Giới hạn trên số instance được khởi chạy, tránh scale quá mức và kiểm soát chi phí.	12 instance

★ Sơ Đồ Auto Scaling Group



★ Giải Thích Ví Dụ

- Ban đầu group khởi chạy ngay **4 instance** (minimum).
- Auto Scaling cố giữ **6 instance** (desired) cho workload hiện tại.
- Khi nhu cầu tăng, group scale out tối đa **12 instance** (maximum).
- Auto Scaling sẽ scale trong khoảng từ minimum đến maximum.

★ Chi Phí

Vì Auto Scaling dùng EC2 instance, bạn **chỉ trả tiền cho instance bạn dùng, khi bạn dùng**. Kiến trúc này tiết kiệm chi phí, mang lại trải nghiệm khách hàng tốt nhất và giảm chi tiêu.

★ Tự Kiểm Tra

Scalability khác elasticity thế nào?

→ Scalability là tiềm năng phát triển dài hạn; elasticity là điều chỉnh tài nguyên động, theo yêu cầu.

Scale up khác scale out thế nào?

→ Scale up thêm sức mạnh cho máy hiện có; scale out thêm nhiều máy.

Dynamic và predictive scaling khác nhau ở đâu?

→ Dynamic điều chỉnh theo thời gian thực; predictive lên lịch trước theo nhu cầu dự đoán.

Không chỉ định desired capacity thì sao?

→ Mặc định bằng minimum capacity.

Tóm Tắt

Scalability là khả năng phát triển dài hạn; elasticity là tự động scale out/in theo nhu cầu. **Amazon EC2 Auto Scaling** điều chỉnh số instance bằng dynamic hoặc predictive scaling, trong giới hạn **minimum, desired, maximum**, và bạn chỉ trả tiền cho phần đã dùng.