

Directing Traffic with Elastic Load Balancing

AWS Cloud Practitioner Essentials › Module 2: Compute in the Cloud › Auto Scaling and Load Balancing

★ Mục Tiêu Bài Học

- Mô tả thách thức của việc phân phối traffic và khả năng mở rộng (scalability) trong môi trường AWS.
- Nhận biết lợi ích của Elastic Load Balancing (ELB).
- Giải thích mối quan hệ giữa Amazon EC2 Auto Scaling và ELB khi quản lý tài nguyên AWS.

Chia đều khối lượng công việc giúp ứng dụng chạy tốt hơn vì **không có tài nguyên đơn lẻ nào** phải tự gánh toàn bộ workload.

Elastic Load Balancing Là Gì?

- Dịch vụ **tự động phân phối** traffic đến của ứng dụng tới nhiều tài nguyên, ví dụ EC2 instances.
- Mục tiêu: tối ưu **hiệu năng** và **độ tin cậy**.
- Là **điểm liên hệ duy nhất** (single point of contact) cho mọi traffic web đi vào một Auto Scaling group.

★ ELB Và EC2 Auto Scaling

Số lượng EC2 instances thay đổi theo nhu cầu traffic. Mọi request luôn đến **load balancer trước**, sau đó được chia đều cho các instance đang có.

ELB và Amazon EC2 Auto Scaling là **hai dịch vụ riêng biệt**, nhưng phối hợp với nhau.

Khi Kết Hợp Cả Hai

- Tăng hiệu năng ứng dụng.
- Đảm bảo **tính sẵn sàng cao** (high availability).
- Ứng dụng trên EC2 mở rộng hiệu quả mà vẫn giữ hiệu năng ổn định.


★ Ba Lợi Ích Chính Của ELB

Lợi ích	Ý nghĩa
Efficient traffic distribution Phân phối traffic hiệu quả	→ Chia đều traffic cho các EC2 instances, tránh quá tải một instance và tối ưu việc sử dụng tài nguyên.
Automatic scaling Tự động mở rộng	→ ELB co giãn theo traffic, tự điều chỉnh khi nhu cầu đổi; vận hành liền mạch khi instance backend được thêm hoặc bớt.
Simplified management Quản lý đơn giản	→ Tách rời (decouple) tầng front-end và backend, giảm đồng bộ thủ công; tự xử lý bảo trì, cập nhật và failover để giảm gánh nặng vận hành.


Các Phương Pháp Định Tuyến

★ Routing Methods


Để tối ưu việc phân phối traffic, ELB dùng nhiều phương pháp định tuyến: **Round Robin**, **Least Connections**, **IP Hash** và **Least Response Time**. Các chiến lược này phối hợp để quản lý traffic hiệu quả và giữ hiệu năng ứng dụng tối ưu.




Round Robin



Least Connections



IP Hash



Least Response Time

★ So Sánh Bốn Phương Pháp

Phương pháp	Cách hoạt động	Đọc từ hình
Round Robin	→ Phân phối traffic đều cho mọi server khả dụng theo vòng tròn .	Năm server đánh số 1 đến 5, request lần lượt đi qua từng server theo chiều mũi tên.
Least Connections	→ Gửi traffic đến server có ít kết nối đang hoạt động nhất , giữ tải cân bằng.	Server bị nhiều luồng dồn vào thì được bỏ qua; request mới đến server chỉ có một luồng.
IP Hash	→ Dùng địa chỉ IP của client để luôn định tuyến về cùng một server.	192.0.2.44 luôn đến cùng một server; 203.0.113.74 không đi vào server đó.
Least Response Time	→ Gửi traffic đến server có thời gian phản hồi nhanh nhất , giảm độ trễ (latency).	Server 35 ms được chọn, server 185 ms thì không.

ELB Và Auto Scaling Group


★ Cách Đọc Sơ Đồ

Người dùng gửi request đến **Elastic Load Balancing** trước. ELB nằm ngoài, đứng trước **Auto Scaling group** (khung nét đứt) và chuyển request tới các EC2 instances bên trong.


Điểm Cần Nhớ

- Người dùng chỉ làm việc với **một điểm vào** là ELB.
- Số instance phía sau có thể tăng hoặc giảm mà người dùng không biết.


1. Nhu cầu thấp: 2 instances



2. Nhu cầu tăng: nhiều người dùng, 4 instances



3. Một instance không hoạt động



Dấu tick: instance bình thường, nhận traffic. Dấu X: instance không hoạt động, traffic không được gửi tới (liên quan đến phần failover mà ELB xử lý).

Ví Dụ Và Tổng Kết

★ Ví Dụ: Cổng Đặt Lịch Của Bệnh Viện

Trong ngành y tế, bệnh viện và cơ sở y khoa có hệ thống đặt lịch hẹn trực tuyến hoặc cổng thông tin bệnh nhân (patient portal). Lượng truy cập web thay đổi rất nhiều trong ngày.

Giờ Nhu Cầu Thấp

- Đầu ngày, chỉ vài bệnh nhân đặt lịch hoặc xem hồ sơ.
- Các web server hiện có đủ sức xử lý.
- Khớp với nhu cầu, **chưa cần thêm tài nguyên**.

Giờ Nhu Cầu Cao

- Giờ cao điểm như sáng sớm hoặc ngay trước cuối tuần: nhiều người đặt lịch, xem kết quả xét nghiệm, liên hệ nhân viên y tế.
- Hệ thống **tự động tăng số lượng server** để luôn phản hồi và sẵn sàng.

★ Luồng Xử Lý Traffic



Nếu một server nhận quá nhiều request, load balancer chuyển request mới sang server **ít bận hơn**, nên không server nào bị quá tải. Traffic được chia đều cho các EC2 instances khả dụng. Nhờ kết hợp ELB và Auto Scaling, hệ thống quản lý hiệu quả lượng bệnh nhân thay đổi và cung cấp truy cập đáng tin cậy ngay cả lúc nhu cầu cao.

Tự Kiểm Tra Và Tóm Tắt

★ Tự Kiểm Tra

ELB làm nhiệm vụ gì?

→ Tự động phân phối traffic đến nhiều tài nguyên như EC2 instances.

Phương pháp nào gửi traffic đến server có ít kết nối nhất?

→ Least Connections.

IP Hash dựa vào đâu để chọn server?

→ Địa chỉ IP của client, để luôn về cùng một server.

ELB và EC2 Auto Scaling có quan hệ thế nào?

→ Hai dịch vụ riêng biệt, phối hợp để tăng hiệu năng và high availability.

Tóm Tắt

ELB là điểm vào duy nhất, chia đều traffic cho các EC2 instances trong Auto Scaling group bằng Round Robin, Least Connections, IP Hash hoặc Least Response Time. Lợi ích: phân phối traffic hiệu quả, tự động mở rộng và quản lý đơn giản.